1 Unificação dos logs e construção de vetores de características

As ferramentas Suricata, Zeek, Wazuh, Cowrie, Dionaea e Heralding registram eventos de segurança em formatos e estruturas distintos. A unificação converte essas informações para um **esquema comum de 26 campos**, preservando a origem do evento e permitindo que uma única etapa posterior de extração produza vetores numéricos de características para modelos de aprendizado de máquina.

1.1 Heterogeneidade dos registros de origem

A Tabela 1 exemplifica diferenças de nomenclatura entre as fontes. A equivalência depende da estrutura específica do log e da existência do campo no evento.

Tabela 1: Exemplos de campos heterogêneos convertidos para o esquema unificado

Ferramenta	**Campo de origem**	**Campo unificado**	**Interpretação**
Suricata	`src_ip`; `dest_ip`	`src_ip`; `dst_ip`	Endereços de origem e destino.
Suricata	`alert.severity`	`severity_orig`; `severity`	Preserva o nível original e produz uma classe comum.
Zeek	`id.orig_h`; `id.resp_h`	`src_ip`; `dst_ip`	Uniformiza a identificação dos dois extremos da conexão.
Zeek	`ts`; `uid`	`timestamp`; `session_id`	Data e identificador da conexão.
Wazuh	`data.srcip`; `rule.level`	`src_ip`; `severity`	Dados extraídos pelo decodificador e severidade da regra.
Cowrie	`eventid`; `input`	`event_type`; `payload`	Identifica a atividade e preserva comandos quando existentes.
Dionaea	`remote_host`; `local_host`	`src_ip`; `dst_ip`	Mapeamento usado para eventos JSON com esses campos.
Heralding	`source_ip`; `destination_ip`	`src_ip`; `dst_ip`	Padronização das origens e destinos de autenticação.

1.2 Estrutura do evento unificado

A Tabela 2 documenta os **26 campos** presentes no esquema do unificador. Nem todos os campos precisam estar preenchidos em todos os eventos: isso depende da ferramenta e do tipo de log.

Tabela 2: Esquema completo dos 26 campos do log unificado

Grupo	**Campo**	**Tipo**	**Papel no registro**
Temporal	`timestamp`	Data/hora	Momento do evento em ISO 8601, normalizado para UTC.
Identificação	`source_tool`	Categoria	Ferramenta responsável pelo registro.
Identificação	`event_type`	Categoria	Tipo de ação observada ou classe de evento.

Continua na próxima página

Continuação da Tabela 2

Grupo	**Campo**	**Tipo**	**Papel no registro**
Rede	`src_ip`	Texto/IP	Endereço IP de origem.
Rede	`src_port`	Inteiro	Porta de origem, quando aplicável.
Rede	`dst_ip`	Texto/IP	Endereço IP de destino.
Rede	`dst_port`	Inteiro	Porta de destino, quando aplicável.
Rede	`proto`	Categoria	Protocolo de transporte (por exemplo, TCP/UDP).
Rede	`app_proto`	Categoria	Protocolo da aplicação (por exemplo, SSH/HTTP).
Alerta	`severity`	Categoria	Severidade convertida para uma escala comum de cinco níveis.
Alerta	`severity_orig`	Número/texto	Severidade original, com significado próprio de cada ferramenta.
Alerta	`signature`	Texto	Regra, descrição ou assinatura relacionada ao evento.
Alerta	`signature_id`	Identificador	Identificador da regra ou assinatura.
Alerta	`category`	Texto	Categoria/classificação disponibilizada pela ferramenta.
Sessão	`session_id`	Identificador	Agrupa eventos de uma mesma sessão ou fluxo.
Autenticação	`username`	Texto	Usuário associado à tentativa de autenticação.
Autenticação	`password`	Texto sensível	Senha observada; requer controle de acesso rigoroso.
Conteúdo	`payload`	Texto	Comando, URL ou informação específica da atividade.
Tráfego	`pkts_to_server`	Inteiro	Quantidade de pacotes enviados ao servidor.
Tráfego	`pkts_to_client`	Inteiro	Quantidade de pacotes enviados ao cliente.
Tráfego	`bytes_to_server`	Inteiro	Quantidade de bytes enviados ao servidor.
Tráfego	`bytes_to_client`	Inteiro	Quantidade de bytes enviados ao cliente.
Tráfego	`duration_s`	Real	Duração observada, em segundos.
Procedência	`agent_name`	Texto	Identificação do agente, quando disponível (por exemplo, Wazuh).
Procedência	`src_log`	Caminho	Arquivo de log de onde o evento foi extraído.
Metadados	`extra`	Objeto/JSON	Preserva atributos específicos da ferramenta não mapeados para o esquema.

1.3 Exemplo de registro padronizado

A Tabela 3 representa **um evento hipotético do Cowrie**, apenas para exemplificar como um registro é preenchido após a unificação. Os demais campos do esquema continuam presentes, podendo conter valores ausentes.

Tabela 3: Exemplo ilustrativo de evento após a unificação

Campo unificado	**Valor do evento hipotético**
`timestamp`	`2026-10-20T14:00:00+00:00`
`source_tool`	`cowrie`
`event_type`	`session.connect`
`src_ip`	`192.168.1.20`
`dst_ip`	`10.0.0.5`
`src_port`	`54321`
`dst_port`	`22`
`proto`	`tcp`
`app_proto`	`ssh`
`severity`	`info`

1.4 Transformação em vetor de características

Na etapa posterior, o extrator interpreta os **mesmos campos padronizados** independentemente da fonte. A Tabela 4 mostra transformações aplicadas pelo extrator corrigido. Os valores numéricos apresentados são ilustrativos; para as categorias, pressupõe-se um codificador previamente ajustado com as respectivas opções.

Tabela 4: Exemplos da transformação de campos unificados em características numéricas

I. unificada	**Valor original**	**Tratamento**	**Saída numérica**
`src_port`	54321	Divisão por 65535	$\approx 0{,}8289$
`dst_port`	22	Divisão por 65535	$\approx 0{,}000336$
`timestamp`	20/10/2026, 14h UTC	Extração da hora e do dia da semana	`hour` $\approx 0{,}6087$; `day_of_week` $\approx 0{,}1667$
`timestamp`	Terça-feira	Indicador de fim de semana	`is_weekend` $= 0$
`src_ip`	192.168.1.20	Validação e teste da faixa privada	`is_src_private`$= 1$
`severity`	`info`	Mapeamento ordinal e divisão por 4	0
`proto`	`tcp`	One-Hot Encoding	`proto_tcp` $= 1$
`source_tool`	`cowrie`	One-Hot Encoding	`source_tool_cowrie` $= 1$
`app_proto`	`ssh`	One-Hot Encoding	`app_proto_ssh` $= 1$
`event_type`	`session.connect`	One-Hot Encoding	`event_type_session.connect` $= 1$
`bytes_to_server`	Contagem observada	$\log(1 + x)$ e MinMaxScaler ajustado no treino	Valor numérico escalonado
Campo numérico ausente	*ausente*	Indicador de ausência e preenchimento controlado	`*_missing` $= 1$

O vetor final reúne essas características e as demais colunas definidas no pré-processador. Seu **número de dimensões depende das categorias observadas no conjunto de treinamento**, mas a dimensão e a ordem das colunas permanecem fixas quando o mesmo codificador é reutilizado na inferência.

1.5 Por que realizar a unificação antes da extração?

Tabela 5: Benefícios das duas etapas do processamento

Etapa	**Problema resolvido**	**Benefício para a análise e a IA**
Logs brutos	Estruturas, nomes e formatos diferentes	Mantém a evidência original, mas ainda dificulta a comparação direta entre fontes.
Unificação	Campos equivalentes com nomenclaturas distintas	Produz um registro interoperável, facilita correlação entre ferramentas e preserva procedência.
Extração	Textos, IPs, datas, categorias e escalas numéricas diversas	Produz características quantitativas apropriadas para modelos de aprendizado de máquina.
Pré-processamento persistido	Colunas e escalas variáveis entre lotes	Mantém a mesma ordem e o mesmo significado das características em treinamento e inferência.

Síntese: a unificação torna os eventos *comparáveis e rastreáveis*; a extração de características os torna *numericamente utilizáveis* por algoritmos de aprendizado de máquina. A unificação não implica que todos os registros contenham os mesmos valores nem que a simples existência de um campo represente um ataque. Identificadores, credenciais e textos livres podem ser preservados no log unificado sem serem incluídos diretamente no vetor inicial.